


LLM Speculative Decoding 发展脉络

从 exact sampling 到 non-AR
drafting 的方法演化

潘乐晗



1. 为什么要做 speculative decoding?

串行解码是瓶颈

问题背景

自回归解码一次只产生 1 个 token; 生成 K 个 token 需要 K 次串行 forward。

在大模型推理中，单步解码常常受限于 memory bandwidth，而不是单纯受限于算力。

- 因此真正值得优化的不是“单步更快”，而是“让一次 target-model 调用尽量多地产生 token”。

一句话理解 SD

先用更便宜的机制提出多 token 草案 (draft)，再由 target model 并行验证 (verify)，从而减少 target model 的调用次数。


本报告路线

前史 → 现代 exact SD → 设计空间
→ 外部 drafter / self-spec / retrieval →
diffusion 前沿

2. 思想前史：从 blockwise parallel decoding 到现代 SD

2018 Blockwise

并行预测多个未来位置，再回退到被 scoring model 验证通过的最长前缀。



2022/23 Leviathan

把 speculative decoding 明确为：由近似模型提案，再由目标模型并行验证，且不改变输出分布。

```
[START] japan ' s benchmark bond n
[START] japan ' s benchmark nikkei 22 .5
[START] japan ' s benchmark nikkei 225 index rose 22 .6
[START] japan ' s benchmark nikkei 225 index rose 226 . 69 . points
[START] japan ' s benchmark nikkei 225 index rose 226 . 69 points , or 0 1
[START] japan ' s benchmark nikkei 225 index rose 226 . 69 points , or 1 . 5 percent , to 10 , 9859
[START] japan ' s benchmark nikkei 225 index rose 226 . 69 points , or 1 . 5 percent , to 10 , 989 . 79 : in
[START] japan ' s benchmark nikkei 225 index rose 226 . 69 points , or 1 . 5 percent , to 10 , 989 . 79 in tokyo late
[START] japan ' s benchmark nikkei 225 index rose 226 . 69 points , or 1 . 5 percent , to 10 , 989 . 79 in late morning trading . [END]
```

2023 Chen

把方法系统化为 speculative sampling + modified rejection sampling.

Stern et al. 提供了“并行提案 + 最长前缀回退”的原型，偏早期的并行解码思路

- Leviathan 与 Chen 则把这一路线推进到现代 exact / lossless speculative decoding。

3. 核心算法: draft—verify + modified rejection sampling

1 Draft

较小/较快的 drafter 先连续提出一段短草案 token。

2 Verify

target model 对整段 continuation 一次性并行打分。

3 Accept / Reject

按 target / draft 的条件概率比, 自左向右决定接受到哪里。

4 Residual

若第一个位置被拒绝, 则从 residual distribution 重新采样; 后续草案作废。

若整段草案均被接受, 最后一次 **target** 打分还可顺手再产生 1 个 token。

```
Sample  $r \sim U[0, 1]$  from a uniform distribution.  
if  $r < \min \left( 1, \frac{q(x|x_1, \dots, x_{n+t-1})}{p(x|x_1, \dots, x_{n+t-1})} \right)$ , then  
    Set  $x_{n+t} \leftarrow \tilde{x}_t$  and  $n \leftarrow n + 1$ .  
else  
    sample  $x_{n+t} \sim (q(x|x_1, \dots, x_{n+t-1}) - p(x|x_1, \dots, x_{n+t-1}))_+$  and exit for loop.
```

4. 用“设计空间”理解后续工作，而不是只看 paper 时间线

A. 提高 **draft** 质量

让更长的草案被接受

关键词: acceptance rate / accepted length

代表: EAGLE、DReSD

B. 降低 **drafting latency**

让“提案本身”足够便宜

代表: Medusa、self-spec、DiffuSpec、DART

C. 优化 **verification** 结构

让一次验证覆盖更多候选

代表: tree attention / dynamic tree

- 三个优化目标是正交的。
- 一篇工作一般能覆盖其中一到两个目标。

5. 外部参数化 drafter: vanilla SD → Medusa

Vanilla speculative decoding


- 独立的小模型 autoregressively 生成 draft
- 理论形式最干净: drafter 与 verifier 分工明确
- 现实挑战: 需要额外模型, 并同时兼顾速度、精度与部署成本

Table 2. Empirical results for speeding up inference from a T5-XXL 11B model.

TASK	M_q	TEMP	γ	α	SPEED
ENDE	T5-SMALL ★	0	7	0.75	3.4X
ENDE	T5-BASE	0	7	0.8	2.8X
ENDE	T5-LARGE	0	7	0.82	1.7X
ENDE	T5-SMALL ★	1	7	0.62	2.6X
ENDE	T5-BASE	1	5	0.68	2.4X
ENDE	T5-LARGE	1	3	0.71	1.4X
CNNDM	T5-SMALL ★	0	5	0.65	3.1X
CNNDM	T5-BASE	0	5	0.73	3.0X
CNNDM	T5-LARGE	0	3	0.74	2.2X
CNNDM	T5-SMALL ★	1	5	0.53	2.3X
CNNDM	T5-BASE	1	3	0.55	2.2X
CNNDM	T5-LARGE	1	3	0.56	1.7X

Medusa


- 在 backbone 顶部增加多个 decoding heads, 而不是维护独立小 LM
- 使用 tree-based attention 组装并验证多条候选 continuation
- 原文区分 Medusa-1 (冻结 backbone) 与 Medusa-2 (联合训练)



6. EAGLE 系列：把“更准的 drafter”做到极致


EAGLE

- 在 second-to-top-layer feature 上做 autoregression 更容易
- 但 feature prediction 存在 uncertainty
- 通过“提前一位的 token 序列”来缓解这一问题
- 摘要报告：LLaMA2-Chat 70B 上 2.7x–3.5x




EAGLE-2

- 观察到 acceptance 不只与树中位置有关，也依赖上下文
- 因而引入 context-aware dynamic draft tree
- 利用 draft model confidence 近似 acceptance
- 摘要报告：3.05x–4.26x



EAGLE-3

- 放弃 feature prediction, 改为 direct token prediction
- 用 multi-layer feature fusion + training-time test
- 摘要报告：up to 6.5x



7. Self-speculative: drafter 与 verifier 可以是同一个模型

Draft & Verify

- 无需 auxiliary model
- drafting 通过“跳过部分中间层”来提速
- verification 再用完整 LLM 一次性检查 draft
- 原文强调：不需要额外训练、不增加额外显存、输出与原模型一致





Figure 3: Illustration of using Bayesian optimization to search the best combination of skip layers that results in the lowest average token inference time.

LayerSkip


- 训练时: layer dropout (后层更高) + early exit loss
- 推理时: 更早的 layer exit 既能直接出结果, 也能作为 self-spec 的 draft stage
- draft / verify 共享计算与激活, 内存占用更低



8. Non-parametric drafter: REST → DReSD


REST

- 用 datastore 替代参数化小模型
- 对当前上下文做 longest-suffix exact match retrieval
- 用检索到的 continuation 构 Trie，并从高频前缀中取 draft
- 再交给 target model 并行验证



DReSD

- 针对 REST 的短板：短上下文 + exact string matching
- 用 contextualized token embeddings + approximate nearest neighbour search 做 dense retrieval
- 原文报告：相对 REST，平均 acceptance 更高、accepted tokens 更长、速度更快



9. 采样过程在数学形式上的优化

Lookahead 的定位

- 原文把它定义为 exact, parallel decoding
- 不需要 auxiliary model, 也不需要 data store
- 通过直接并行抽取并验证 n-grams 来减少 decoding steps

$$\begin{cases} y_1 = \operatorname{argmax} P_M(y_1|\mathbf{x}^0) \\ y_2 = \operatorname{argmax} P_M(y_2|y_1, \mathbf{x}^0) \\ \dots \\ y_m = \operatorname{argmax} P_M(y_m|y_{1:m-1}, \mathbf{x}^0) \end{cases}$$

$$\begin{cases} f(y_1, \mathbf{x}^0) = 0 \\ f(y_2, y_1, \mathbf{x}^0) = 0 \\ \dots \\ f(y_m, y_{1:m-1}, \mathbf{x}^0) = 0 \end{cases}$$

Travesal Verification

- 原始的采样过程是逐token的, 当前token的拒绝概率高不代表后续路径拒绝概率高
- 如果后续token接受概率高, 其实可以拉高这条路径的接受概率, 但是已经被第一个拒绝概率高的token阻断了
- 能否从更加全局的角度进行采样?

Table 3: Acceptance length and throughput on Llama-68M with Llama2-7B.

Llama-68M (draft) & Llama2-7B (target) Temperature=1									
Tasks	Chain			Binary Tree			EAGLE Sparse Tree		
	Tok.V	Tra.V	Δ	Tok.V	Tra.V	Δ	Tok.V	Tra.V	Δ
Multi-turn	2.05 $\pm$ 0.05	2.16 $\pm$ 0.03	5.5%	2.47 $\pm$ 0.01	2.59 $\pm$ 0.01	4.7%	2.55 $\pm$ 0.02	2.70 $\pm$ 0.02	5.6%
Translation	1.97 $\pm$ 0.05	2.10 $\pm$ 0.05	6.3%	2.38 $\pm$ 0.01	2.43 $\pm$ 0.03	2.1%	2.49 $\pm$ 0.01	2.51 $\pm$ 0.03	0.9%
Sum.	1.77 $\pm$ 0.04	1.86 $\pm$ 0.05	4.9%	2.14 $\pm$ 0.01	2.27 $\pm$ 0.03	5.8%	2.25 $\pm$ 0.02	2.36 $\pm$ 0.02	4.7%
QA	2.07 $\pm$ 0.01	2.19 $\pm$ 0.02	5.6%	2.59 $\pm$ 0.05	2.71 $\pm$ 0.01	4.8%	2.63 $\pm$ 0.02	2.69 $\pm$ 0.02	2.2%
Math	2.01 $\pm$ 0.05	2.15 $\pm$ 0.04	7.0%	2.49 $\pm$ 0.05	2.67 $\pm$ 0.06	7.0%	2.57 $\pm$ 0.02	2.72 $\pm$ 0.01	6.0%
RAG	2.09 $\pm$ 0.05	2.19 $\pm$ 0.03	4.8%	2.56 $\pm$ 0.05	2.69 $\pm$ 0.05	5.0%	2.63 $\pm$ 0.02	2.71 $\pm$ 0.06	3.2%
Avg. Accept.	1.99 $\pm$ 0.01	2.10 $\pm$ 0.01	5.7%	2.44 $\pm$ 0.03	2.56 $\pm$ 0.01	4.9%	2.52 $\pm$ 0.01	2.62 $\pm$ 0.01	3.8%
Avg. Token/s	58.0 $\pm$ 0.7	60.8 $\pm$ 0.8	4.8%	59.4 $\pm$ 0.8	61.6 $\pm$ 0.6	3.7%	69.1 $\pm$ 0.9	71.2 $\pm$ 1.0	3.0%

10. 最新前沿：当 drafting latency 成为瓶颈，diffusion 线出现了

DiffuSpec

- 直接把 pretrained diffusion language model 当作 drafter
- 单次 forward 产生多 token draft
- 为兼容 AR verifier, 引入 CPS (causal-consistency path search) 与 ADL (adaptive draft length)
- 原文报告: up to 3x wall-clock speedup

DART

- 受 diffusion 启发, 但不是简单复用现成 DLM
- 在单次 forward 中并行预测多个未来 masked positions 的 logits
- 再做 tree pruning, 并使用 N-gram-enforced semantic continuity
- 原文报告: 2.03x–3.44x, 平均优于 EAGLE-3

11. 结论：如何像研究者一样理解 speculative decoding

结论 1

Speculative decoding 的本质不是“多猜几个 token”，而是：在 draft—verify—correct 后，依然保持 target model 的输出分布。

结论 2

方法演化的主线不是“谁更新”，而是：谁在更高效地平衡 acceptance、draft latency 与 verification 结构。

结论 3

前沿正在从“更强 drafter”继续走向 non-AR drafting、异步化验证，以及更系统层面的并行结构。

参考文献

Stern et al., Blockwise Parallel Decoding for Deep Autoregressive Models, NeurIPS 2018.

Leviathan et al., Fast Inference from Transformers via Speculative Decoding, ICML 2023.

Chen et al., Accelerating Large Language Model Decoding with Speculative Sampling, 2023.

Cai et al., Medusa: Simple LLM Inference Acceleration Framework with Multiple Decoding Heads, ICML 2024.

Li et al., EAGLE / EAGLE-2 / EAGLE-3, 2024–2025.

Zhang et al., Draft & Verify, ACL 2024; Elhoushi et al., LayerSkip, 2024.

He et al., REST, NAACL 2024; Gritta et al., DReSD, Findings ACL 2025.

- Fu et al., Lookahead Decoding, 2024; DiffuSpec / DART, 2025–2026.